



EAD - Polo Santa Luiza – Vitória – ES

DESENVOLVIMENTO FULL STACK

RELATÓRIO DO TRABALHO AVALIATIVO MUNDO 5 – NÍVEL 5

DGT2823 - Tecnologias para desenvolvimento de soluções de big data

CARLOS ALTOMARE CATÃO

Matrícula: 202403460912

Semestre Letivo: 2026/1 - 5º Período

Data: 2026/05

Limpeza de um conjunto de dados, tornando-o apto a ser usado em tarefas de mineração/análise de dados.

OBJETIVO

Este relatório apresenta o desenvolvimento do trabalho prático de limpeza e tratamento de dados utilizando a linguagem Python e a biblioteca Pandas. O objetivo principal foi preparar um conjunto de dados em formato CSV para utilização em processos de mineração, análise e interpretação de dados.

CONTEXTUALIZAÇÃO

Na prática de um Analista de Dados é fundamental tratar um conjunto de dados a fim de que estejam organizados e consistentes antes de qualquer processo analítico. A atividade proposta teve como foco aplicar técnicas de *Data Cleaning* para corrigir inconsistências, tratar valores nulos e converter tipos de dados inadequados, garantindo maior qualidade e confiabilidade ao conjunto de dados utilizado.

Para tal tarefa foram utilizadas a linguagem Python e a biblioteca Pandas em um ambiente no JupyterLab.

REQUISITOS

- Python 3.x;
- Biblioteca pandas;
- Jupyter Notebook, JupyterLab ou Google Colab;
- Editor ou IDE para desenvolvimento (VS Code, PyCharm, entre outros);
- Arquivo de dados no formato CSV (“picoweb.csv”).

FERRAMENTAS E TECNOLOGIAS UTILIZADAS

Durante o desenvolvimento da atividade foram utilizadas as seguintes tecnologias:

- Linguagem Python
- Biblioteca Pandas
- JupyterLab para execução e documentação do código
- Ambiente VS Code para edição complementar

ETAPAS REALIZADAS

1. Leitura do arquivo CSV utilizando `pandas.read_csv()`.
2. Verificação inicial do *DataFrame* por meio dos métodos `.info()`, `.head()` e `.tail()`
3. Criação de uma cópia independente dos dados para preservar o conjunto original.
4. Tratamento de valores nulos nas colunas **Calories** e **Date**.
5. Conversão da coluna **Date** para o tipo *datetime*.
6. Correção de formatos inconsistentes, incluindo registros inválidos.
7. Remoção de registros nulos remanescentes utilizando `.dropna()`.
8. Verificação final do *DataFrame* após as transformações realizadas.

DESAFIOS TÉCNICOS E SOLUÇÕES

Durante o desenvolvimento do projeto, alguns desafios foram identificados:

- Existência de valores nulos em colunas importantes do *Dataset*.
Solução: aplicação de substituições e tratamento adequado utilizando recursos do **Pandas**.
- Inconsistência no formato das datas.
Solução: utilização das funções `replace()` e `to_datetime()` para padronização.
- Preservação do conjunto original de dados.
Solução: criação de uma cópia independente do *DataFrame* antes das alterações.

✅ RESULTADOS OBTIDOS

Ao final da atividade, o conjunto de dados apresentou os seguintes resultados:

- Ausência de valores nulos nas colunas essenciais.
- Conversão correta da coluna **Date** para o formato *datetime64*.
- *Dataset* organizado e preparado para futuras análises estatísticas, visualizações e modelagem preditiva.
- Melhor qualidade e consistência dos dados tratados.

📌 CONCLUSÃO

A atividade permitiu aplicar conceitos importantes de limpeza e tratamento de dados utilizando Python e Pandas. O processo demonstrou a importância da preparação adequada dos dados antes da realização de análises mais avançadas.

O projeto atingiu os objetivos propostos, resultando em um *Dataset* consistente, organizado e apto para utilização em tarefas de análise de dados.
