

In [162... *# Importando as Bibliotecas de Trabalho*

```
import pandas as pd
import numpy as np
```

In [163... *# Criando a Variável para armazenar o arquivo*

```
dados_csv = None
```

In [164... *# Leitura do Arquivo CSV atribuindo as informacoes lidas para a variavel ja defi*

```
dados_csv = pd.read_csv(
    './data/picoweb.csv', # caminho do arquivo
    sep=';',              # separador de colunas
    engine='python',      # engine
    encoding='utf-8'      # encoding
)
```

In [165... *# Listagem do arquivo original para efeito de comparacoes futuras*

```
print("="*65)
print("          LISTAGEM DO ARQUIVO ORIGINAL PARA BASE DE COMPARAÇÕES"+"\\n")
print(dados_csv)
print("="*65)
```

LISTAGEM DO ARQUIVO ORIGINAL PARA BASE DE COMPARAÇÕES

	ID	Duration	Date	Pulse	Maxpulse	Calories
0	0	60	'2020/12/01'	110	130	4091.0
1	1	60	'2020/12/02'	117	145	4790.0
2	2	60	'2020/12/03'	103	135	3400.0
3	3	45	'2020/12/04'	109	175	2824.0
4	4	45	'2020/12/05'	117	148	4060.0
5	5	60	'2020/12/06'	102	127	3000.0
6	6	60	'2020/12/07'	110	136	3740.0
7	7	450	'2020/12/08'	104	134	2533.0
8	8	30	'2020/12/09'	109	133	1951.0
9	9	60	'2020/12/10'	98	124	2690.0
10	10	60	'2020/12/11'	103	147	3293.0
11	11	60	'2020/12/12'	100	120	2507.0
12	12	60	'2020/12/12'	100	120	2507.0
13	13	60	'2020/12/13'	106	128	3453.0
14	14	60	'2020/12/14'	104	132	3793.0
15	15	60	'2020/12/15'	98	123	2750.0
16	16	60	'2020/12/16'	98	120	2152.0
17	17	60	'2020/12/17'	100	120	3000.0
18	18	45	'2020/12/18'	90	112	NaN
19	19	60	'2020/12/19'	103	123	3230.0
20	20	45	'2020/12/20'	97	125	2430.0
21	21	60	'2020/12/21'	108	131	3642.0
22	22	45	NaN	100	119	2820.0
23	23	60	'2020/12/23'	130	101	3000.0
24	24	45	'2020/12/24'	105	132	2460.0
25	25	60	'2020/12/25'	102	126	3345.0
26	26	60	20201226	100	120	2500.0
27	27	60	'2020/12/27'	92	118	2410.0
28	28	60	'2020/12/28'	103	132	NaN
29	29	60	'2020/12/29'	100	132	2800.0
30	30	60	'2020/12/30'	102	129	3803.0
31	31	60	'2020/12/31'	92	115	2430.0

In [166... *# Verificando a importacao dos dados*

```
print("="*65)
print("    INFORMAÇÕES GERAIS PARA VERIFICAR A IMPORTAÇÃO DOS DADOS"+"\\n")
print(dados_csv.info())
print("\\n==> PRIMEIRAS 5 LINHAS"+"\\n")
print(dados_csv.head())
print("\\n==> ÚLTIMAS 5 LINHAS"+"\\n")
print(dados_csv.tail())
print("="*65)
```

=====

INFORMAÇÕES GERAIS PARA VERIFICAR A IMPORTAÇÃO DOS DADOS

```
<class 'pandas.DataFrame'>
RangeIndex: 32 entries, 0 to 31
Data columns (total 6 columns):
#   Column      Non-Null Count  Dtype
---  ---
0    ID          32 non-null    int64
1   Duration    32 non-null    int64
2    Date        31 non-null    str
3   Pulse       32 non-null    int64
4   Maxpulse    32 non-null    int64
5   Calories     30 non-null    float64
dtypes: float64(1), int64(4), str(1)
memory usage: 1.6 KB
None
```

==> PRIMEIRAS 5 LINHAS

	ID	Duration	Date	Pulse	Maxpulse	Calories
0	0	60	'2020/12/01'	110	130	4091.0
1	1	60	'2020/12/02'	117	145	4790.0
2	2	60	'2020/12/03'	103	135	3400.0
3	3	45	'2020/12/04'	109	175	2824.0
4	4	45	'2020/12/05'	117	148	4060.0

==> ÚLTIMAS 5 LINHAS

	ID	Duration	Date	Pulse	Maxpulse	Calories
27	27	60	'2020/12/27'	92	118	2410.0
28	28	60	'2020/12/28'	103	132	NaN
29	29	60	'2020/12/29'	100	132	2800.0
30	30	60	'2020/12/30'	102	129	3803.0
31	31	60	'2020/12/31'	92	115	2430.0

=====

In [167... *# Criando uma nova variável com cópia dos dados*

```
dados_csv_copia = dados_csv.copy()
```

In [168... *# Substituindo os valores nulos da coluna 'Calories' por 0*

```
dados_csv_copia['Calories'] = dados_csv_copia['Calories'].fillna(0)

# Imprimindo os novos valores apos a substituição

print("="*65)
print("***  DESAFIO 01 - SUBSTITUIÇÃO DE <Calories> NULOS POR 0 (ZERO)+"+"\n")

print("==> APÓS SUBSTITUIR NULOS POR 0")
print(dados_csv_copia)
print("="*65)
```

```
=====
*** DESAFIO 01 - SUBSTITUIÇÃO DE <Calories> NULOS POR 0 (ZERO)

==> APÓS SUBSTITUIR NULOS POR 0
```

	ID	Duration	Date	Pulse	Maxpulse	Calories
0	0	60	'2020/12/01'	110	130	4091.0
1	1	60	'2020/12/02'	117	145	4790.0
2	2	60	'2020/12/03'	103	135	3400.0
3	3	45	'2020/12/04'	109	175	2824.0
4	4	45	'2020/12/05'	117	148	4060.0
5	5	60	'2020/12/06'	102	127	3000.0
6	6	60	'2020/12/07'	110	136	3740.0
7	7	450	'2020/12/08'	104	134	2533.0
8	8	30	'2020/12/09'	109	133	1951.0
9	9	60	'2020/12/10'	98	124	2690.0
10	10	60	'2020/12/11'	103	147	3293.0
11	11	60	'2020/12/12'	100	120	2507.0
12	12	60	'2020/12/12'	100	120	2507.0
13	13	60	'2020/12/13'	106	128	3453.0
14	14	60	'2020/12/14'	104	132	3793.0
15	15	60	'2020/12/15'	98	123	2750.0
16	16	60	'2020/12/16'	98	120	2152.0
17	17	60	'2020/12/17'	100	120	3000.0
18	18	45	'2020/12/18'	90	112	0.0
19	19	60	'2020/12/19'	103	123	3230.0
20	20	45	'2020/12/20'	97	125	2430.0
21	21	60	'2020/12/21'	108	131	3642.0
22	22	45	NaN	100	119	2820.0
23	23	60	'2020/12/23'	130	101	3000.0
24	24	45	'2020/12/24'	105	132	2460.0
25	25	60	'2020/12/25'	102	126	3345.0
26	26	60	20201226	100	120	2500.0
27	27	60	'2020/12/27'	92	118	2410.0
28	28	60	'2020/12/28'	103	132	0.0
29	29	60	'2020/12/29'	100	132	2800.0
30	30	60	'2020/12/30'	102	129	3803.0
31	31	60	'2020/12/31'	92	115	2430.0

```
=====
```

Se observarmos as linhas 18 e 28 poderemos ver as substituições efetuadas.

In [169...

```
# Substituindo os valores nulos da coluna 'Date' por '1900/01/01'

dados_csv_copia['Date'] = dados_csv_copia['Date'].fillna("'1900/01/01'")

# Imprimindo os novos valores apos a substituição

print("="*65)
print("*** DESAFIO 02 - SUBSTITUIÇÃO DE <Date> NULOS POR '1900/01/01'+"\n")

print("==> APÓS SUBSTITUIR NULOS POR '1900/01/01'")
print(dados_csv_copia)
print("="*65)
```

```
=====
*** DESAFIO 02 - SUBSTITUIÇÃO DE <Date> NULOS POR '1900/01/01'

==> APÓS SUBSTITUIR NULOS POR '1900/01/01'
  ID  Duration      Date  Pulse  Maxpulse  Calories
0    0         60  '2020/12/01'   110      130    4091.0
1    1         60  '2020/12/02'   117      145    4790.0
2    2         60  '2020/12/03'   103      135    3400.0
3    3         45  '2020/12/04'   109      175    2824.0
4    4         45  '2020/12/05'   117      148    4060.0
5    5         60  '2020/12/06'   102      127    3000.0
6    6         60  '2020/12/07'   110      136    3740.0
7    7        450  '2020/12/08'   104      134    2533.0
8    8         30  '2020/12/09'   109      133    1951.0
9    9         60  '2020/12/10'    98      124    2690.0
10  10         60  '2020/12/11'   103      147    3293.0
11  11         60  '2020/12/12'   100      120    2507.0
12  12         60  '2020/12/12'   100      120    2507.0
13  13         60  '2020/12/13'   106      128    3453.0
14  14         60  '2020/12/14'   104      132    3793.0
15  15         60  '2020/12/15'    98      123    2750.0
16  16         60  '2020/12/16'    98      120    2152.0
17  17         60  '2020/12/17'   100      120    3000.0
18  18         45  '2020/12/18'    90      112      0.0
19  19         60  '2020/12/19'   103      123    3230.0
20  20         45  '2020/12/20'    97      125    2430.0
21  21         60  '2020/12/21'   108      131    3642.0
22  22         45  '1900/01/01'   100      119    2820.0
23  23         60  '2020/12/23'   130      101    3000.0
24  24         45  '2020/12/24'   105      132    2460.0
25  25         60  '2020/12/25'   102      126    3345.0
26  26         60    20201226   100      120    2500.0
27  27         60  '2020/12/27'    92      118    2410.0
28  28         60  '2020/12/28'   103      132      0.0
29  29         60  '2020/12/29'   100      132    2800.0
30  30         60  '2020/12/30'   102      129    3803.0
31  31         60  '2020/12/31'    92      115    2430.0
=====
```

Se observarmos a linha 22 poderemos ver a substituição efetuada.

In [170...

```
# Transformar a coluna Date para datetime

print("="*65)
print("*** DESAFIO 03 - TRANSFORMAÇÃO DA COLUNA <Date> em DATETIME'"+ "\n")

try:
    dados_csv_copia['Date'] = pd.to_datetime(dados_csv_copia['Date'], format='%Y
except Exception as e:
    print(f"==> NA TENTATIVA DE TRANSFORMAÇÃO OCORREU <ERRO>\n\n {e}")

print("\nEste ERRO se deve ao fato de que os valores de data estão entre aspas s
print("Para resolver será necessário retirar as aspas.")
print("="*65)
```

=====

*** DESAFIO 03 - TRANSFORMAÇÃO DA COLUNA <Date> em DATETIME'

==> NA TENTATIVA DE TRANSFORMAÇÃO OCORREU <ERRO>

time data "'2020/12/01'" doesn't match format "%Y/%m/%d". You might want to try:

- passing `format` if your strings have a consistent format;
- passing `format='ISO8601'` if your strings are all ISO8601 but not necessarily in exactly the same format;
- passing `format='mixed'`, and the format will be inferred for each element individually. You might want to use `dayfirst` alongside this.

Este ERRO se deve ao fato de que os valores de data estão entre aspas simples. Para resolver será necessário retirar as aspas.

=====

No arquivo original todas as datas encontram-se entre aspas simples.

In [171...

```
# Revertendo na coluna 'Date', o valor '1900/01/01' por 'NaN'

dados_csv_copia['Date'] = dados_csv_copia['Date'].replace("'1900/01/01'", np.nan)

print("="*65)
print("*** DESAFIO 03 - REVERTENDO O VALOR DE <Date> DE '1900/01/01' PARA NULO")
print(dados_csv_copia)
print("="*65)
```

```
=====
*** DESAFIO 03 - REVERTENDO O VALOR DE <Date> DE '1900/01/01' PARA NULO'
```

	ID	Duration	Date	Pulse	Maxpulse	Calories
0	0	60	'2020/12/01'	110	130	4091.0
1	1	60	'2020/12/02'	117	145	4790.0
2	2	60	'2020/12/03'	103	135	3400.0
3	3	45	'2020/12/04'	109	175	2824.0
4	4	45	'2020/12/05'	117	148	4060.0
5	5	60	'2020/12/06'	102	127	3000.0
6	6	60	'2020/12/07'	110	136	3740.0
7	7	450	'2020/12/08'	104	134	2533.0
8	8	30	'2020/12/09'	109	133	1951.0
9	9	60	'2020/12/10'	98	124	2690.0
10	10	60	'2020/12/11'	103	147	3293.0
11	11	60	'2020/12/12'	100	120	2507.0
12	12	60	'2020/12/12'	100	120	2507.0
13	13	60	'2020/12/13'	106	128	3453.0
14	14	60	'2020/12/14'	104	132	3793.0
15	15	60	'2020/12/15'	98	123	2750.0
16	16	60	'2020/12/16'	98	120	2152.0
17	17	60	'2020/12/17'	100	120	3000.0
18	18	45	'2020/12/18'	90	112	0.0
19	19	60	'2020/12/19'	103	123	3230.0
20	20	45	'2020/12/20'	97	125	2430.0
21	21	60	'2020/12/21'	108	131	3642.0
22	22	45	NaN	100	119	2820.0
23	23	60	'2020/12/23'	130	101	3000.0
24	24	45	'2020/12/24'	105	132	2460.0
25	25	60	'2020/12/25'	102	126	3345.0
26	26	60	20201226	100	120	2500.0
27	27	60	'2020/12/27'	92	118	2410.0
28	28	60	'2020/12/28'	103	132	0.0
29	29	60	'2020/12/29'	100	132	2800.0
30	30	60	'2020/12/30'	102	129	3803.0
31	31	60	'2020/12/31'	92	115	2430.0

```
=====
```

In [172...

```
# Removendo as aspas para eliminar o ERRO

dados_csv_copia['Date'] = dados_csv_copia['Date'].str.strip('"')

print("="*65)
print("*** DESAFIO 04 - REMOVENDO AS ASPAS E TENTANDO NOVAMENTE A TRANSFORMAÇÃO

# Agora tentar converter para datetime novamente
try:
    dados_csv_copia['Date'] = pd.to_datetime(dados_csv_copia['Date'], format='%Y
    print("\n\nConversão bem sucedida!")
except Exception as e:
    print(f"==> NA NOVA TENTATIVA DE TRANSFORMAÇÃO OCORREU <ERRO>\n\n {e}")

print('\nEste ERRO se deve ao fato de que na linha 26 a data nao está separada p
print("="*65)
```

```
=====
*** DESAFIO 04 - REMOVENDO AS ASPAS E TENTANDO NOVAMENTE A TRANSFORMAÇÃO DA COLU
NA <Date> EM DATETIME'
```

```
==> NA NOVA TENTATIVA DE TRANSFORMAÇÃO OCORREU <ERRO>
```

```
time data "20201226" doesn't match format "%Y/%m/%d". You might want to try:
- passing `format` if your strings have a consistent format;
- passing `format='ISO8601'` if your strings are all ISO8601 but not necessar
ily in exactly the same format;
- passing `format='mixed'`, and the format will be inferred for each element
individually. You might want to use `dayfirst` alongside this.
```

Este ERRO se deve ao fato de que na linha 26 a data não está separada por "/".

```
=====
```

In [173...

```
# Combinando replace e to_datetime
dados_csv_copia['Date'] = dados_csv_copia['Date'].replace(
    '20201226',
    pd.to_datetime('2020/12/26', format='%Y/%m/%d').date()
)

print("="*65)
print("*** DESAFIO 05 - CONVERTENDO A DATA 20201226 PARA 2020/12/26'"+ "\n")
print(dados_csv_copia)
print("="*65)
```


=====

*** DESAFIO 05 - CONVERTENDO A DATA 20201226 PARA 2020/12/26'

	ID	Duration	Date	Pulse	Maxpulse	Calories
0	0	60	2020/12/01	110	130	4091.0
1	1	60	2020/12/02	117	145	4790.0
2	2	60	2020/12/03	103	135	3400.0
3	3	45	2020/12/04	109	175	2824.0
4	4	45	2020/12/05	117	148	4060.0
5	5	60	2020/12/06	102	127	3000.0
6	6	60	2020/12/07	110	136	3740.0
7	7	450	2020/12/08	104	134	2533.0
8	8	30	2020/12/09	109	133	1951.0
9	9	60	2020/12/10	98	124	2690.0
10	10	60	2020/12/11	103	147	3293.0
11	11	60	2020/12/12	100	120	2507.0
12	12	60	2020/12/12	100	120	2507.0
13	13	60	2020/12/13	106	128	3453.0
14	14	60	2020/12/14	104	132	3793.0
15	15	60	2020/12/15	98	123	2750.0
16	16	60	2020/12/16	98	120	2152.0
17	17	60	2020/12/17	100	120	3000.0
18	18	45	2020/12/18	90	112	0.0
19	19	60	2020/12/19	103	123	3230.0
20	20	45	2020/12/20	97	125	2430.0
21	21	60	2020/12/21	108	131	3642.0
22	22	45	NaN	100	119	2820.0
23	23	60	2020/12/23	130	101	3000.0
24	24	45	2020/12/24	105	132	2460.0
25	25	60	2020/12/25	102	126	3345.0
26	26	60	2020-12-26	100	120	2500.0
27	27	60	2020/12/27	92	118	2410.0
28	28	60	2020/12/28	103	132	0.0
29	29	60	2020/12/29	100	132	2800.0
30	30	60	2020/12/30	102	129	3803.0
31	31	60	2020/12/31	92	115	2430.0

=====

Na linha 26 podemos observar a data separada por -. Isso acontece porque o pandas, por padrão, exibe datas no formato ISO 8601 que é YYYY-MM-DD (com hífen), independentemente do formato que você usou na conversão.

In [174...

```
print("="*65)
print("*** DESAFIO 06 - FAZENDO A CONVERSÃO DE TODOS OS DADOS DA COLUMNA <Date> P

# Agora tentar converter para datetime novamente
try:
    dados_csv_copia['Date'] = pd.to_datetime(dados_csv_copia['Date'], format='%Y
    print("\nConversão bem sucedida!\n")
except Exception as e:
    print(f"==> NA NOVA TENTATIVA DE TRANSFORMAÇÃO OCORREU <ERRO>\n\n {e}")

print(dados_csv_copia)
print("="*65)
```

```
=====
*** DESAFIO 06 - FAZENDO A CONVERSÃO DE TODOS OS DADOS DA COLUNA <Date> PARA DATE
TIME'
```

Conversão bem sucedida!

	ID	Duration	Date	Pulse	Maxpulse	Calories
0	0	60	2020-12-01	110	130	4091.0
1	1	60	2020-12-02	117	145	4790.0
2	2	60	2020-12-03	103	135	3400.0
3	3	45	2020-12-04	109	175	2824.0
4	4	45	2020-12-05	117	148	4060.0
5	5	60	2020-12-06	102	127	3000.0
6	6	60	2020-12-07	110	136	3740.0
7	7	450	2020-12-08	104	134	2533.0
8	8	30	2020-12-09	109	133	1951.0
9	9	60	2020-12-10	98	124	2690.0
10	10	60	2020-12-11	103	147	3293.0
11	11	60	2020-12-12	100	120	2507.0
12	12	60	2020-12-12	100	120	2507.0
13	13	60	2020-12-13	106	128	3453.0
14	14	60	2020-12-14	104	132	3793.0
15	15	60	2020-12-15	98	123	2750.0
16	16	60	2020-12-16	98	120	2152.0
17	17	60	2020-12-17	100	120	3000.0
18	18	45	2020-12-18	90	112	0.0
19	19	60	2020-12-19	103	123	3230.0
20	20	45	2020-12-20	97	125	2430.0
21	21	60	2020-12-21	108	131	3642.0
22	22	45	NaT	100	119	2820.0
23	23	60	2020-12-23	130	101	3000.0
24	24	45	2020-12-24	105	132	2460.0
25	25	60	2020-12-25	102	126	3345.0
26	26	60	2020-12-26	100	120	2500.0
27	27	60	2020-12-27	92	118	2410.0
28	28	60	2020-12-28	103	132	0.0
29	29	60	2020-12-29	100	132	2800.0
30	30	60	2020-12-30	102	129	3803.0
31	31	60	2020-12-31	92	115	2430.0

```
In [175... # Verificar e remover registros com valores nulos em QUALQUER coluna

print("*** DESAFIO 07 - VERIFICANDO VALORES NULOS EM TODAS AS COLUNAS"+"\\n")
print(f"Total de registros antes da remoção: {len(dados_csv_copia)}")

# Verificar valores nulos em todas as colunas
print("\\n✅ CONTAGEM DE VALORES NULOS POR COLUNA")
for coluna in dados_csv_copia.columns:
    nulos = dados_csv_copia[coluna].isna().sum()
    if nulos > 0:
        print(f" - {coluna}: {nulos} valor(es) nulo(s)")

# Mostrar quais linhas têm valores nulos em qualquer coluna
linhas_com_nulos = dados_csv_copia[dados_csv_copia.isna().any(axis=1)]
print(f"\\n✅ LINHAS QUE CONTÊM VALORES NULOS")
print(f" Total de linhas com algum valor nulo: {len(linhas_com_nulos)}\\n")
print(linhas_com_nulos)
```

```
# Remover linhas que tenham QUALQUER valor nulo
dados_csv_copia = dados_csv_copia.dropna()

print(f"\n✅ Total de registros após remoção: {len(dados_csv_copia)}")
print(f"✅ Valores nulos restantes: {dados_csv_copia.isna().sum().sum()}")
print("="*65)
```

*** DESAFIO 07 - VERIFICANDO VALORES NULOS EM TODAS AS COLUNAS

Total de registros antes da remoção: 32

✅ CONTAGEM DE VALORES NULOS POR COLUNA
- Date: 1 valor(es) nulo(s)

✅ LINHAS QUE CONTÊM VALORES NULOS
Total de linhas com algum valor nulo: 1

	ID	Duration	Date	Pulse	Maxpulse	Calories
22	22	45	NaT	100	119	2820.0

✅ Total de registros após remoção: 31

✅ Valores nulos restantes: 0

In [178...

```
# Imprimir o dataframe e verificar todas as transformações

print("*** DATAFRAME FINAL APÓS TODAS AS TRANSFORMAÇÕES"+"\\n")

# Imprimir o DataFrame completo
print("\\n==> DATAFRAME FINAL\\n")
print(dados_csv_copia)
print("="*65)
```

*** DATAFRAME FINAL APÓS TODAS AS TRANSFORMAÇÕES

===> DATAFRAME FINAL

	ID	Duration	Date	Pulse	Maxpulse	Calories
0	0	60	2020-12-01	110	130	4091.0
1	1	60	2020-12-02	117	145	4790.0
2	2	60	2020-12-03	103	135	3400.0
3	3	45	2020-12-04	109	175	2824.0
4	4	45	2020-12-05	117	148	4060.0
5	5	60	2020-12-06	102	127	3000.0
6	6	60	2020-12-07	110	136	3740.0
7	7	450	2020-12-08	104	134	2533.0
8	8	30	2020-12-09	109	133	1951.0
9	9	60	2020-12-10	98	124	2690.0
10	10	60	2020-12-11	103	147	3293.0
11	11	60	2020-12-12	100	120	2507.0
12	12	60	2020-12-12	100	120	2507.0
13	13	60	2020-12-13	106	128	3453.0
14	14	60	2020-12-14	104	132	3793.0
15	15	60	2020-12-15	98	123	2750.0
16	16	60	2020-12-16	98	120	2152.0
17	17	60	2020-12-17	100	120	3000.0
18	18	45	2020-12-18	90	112	0.0
19	19	60	2020-12-19	103	123	3230.0
20	20	45	2020-12-20	97	125	2430.0
21	21	60	2020-12-21	108	131	3642.0
23	23	60	2020-12-23	130	101	3000.0
24	24	45	2020-12-24	105	132	2460.0
25	25	60	2020-12-25	102	126	3345.0
26	26	60	2020-12-26	100	120	2500.0
27	27	60	2020-12-27	92	118	2410.0
28	28	60	2020-12-28	103	132	0.0
29	29	60	2020-12-29	100	132	2800.0
30	30	60	2020-12-30	102	129	3803.0
31	31	60	2020-12-31	92	115	2430.0

=====

Como podemos verificar todas as modificações solicitadas foram efetuadas e o registro 22 foi removido.